图分析说明文档

江俊广 2015011584
毛誉陶 2016013249

目录

一、 概述

- 选取的数据集：「豆瓣影评数据」和自采数据集「知乎话题数据」。
- 框架及流程

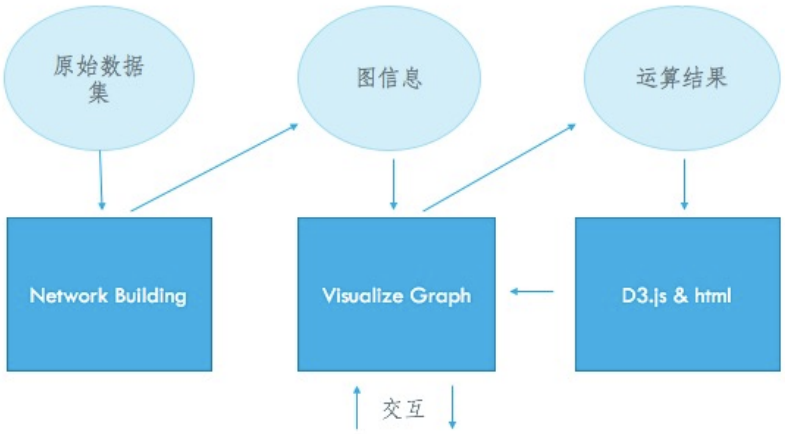

我们的图分析程序主要由三部分构成。

首先是用C++进行网络图的构建（NetworkBuilding），由于该部分占用较多的时间和空间资源，在得到结果文件（”output/network.csv”）后就不再运行。

然后用C++进行核心算法的实现（VisualizeGraph)，并且将计算得到的结果输出到json文件。

最后用QT和D3实现算法的可视化，QT主要用于接受用户的输入，D3实现了图的可视化。

- 程序运行环境：Mac

二、 必做项说明（核心算法的实现）

由于全图较为稀疏，因此采用邻接表存储。每个节点存储所有关联边的编号，同时每条边也存储所有关联节点的编号。设总节点数目为n，总边数为e。

■ 根据用户指定计算最短路径

最短路径采用Dijkstra算法，最小生成树采用Prim算法，两种算法本质上都是优先级搜索，不同点在于优先级计算方式不同，因此程序中统一采用优先级搜索PFS进行

实现。

单连通域优先级搜索（PFS）的实现算法

1. 所有节点处于未访问状态，所有节点的优先级数都为最低。维护一个优先级队列，将搜索的起始节点的一个拷贝加入队列。
2. 如果优先级队列为空，则搜索完毕。否则，从优先级队列中弹出优先级最高的节点，如果发现该节点拷贝对应的原节点已经被访问，则舍弃该节点；否则访问原节点。转3。
3. 更新原节点的所有邻居节点的优先级数，并且将那些优先级发生了更新的邻居节点的拷贝加入到优先级队列（此处采用懒惰删除策略，尽管优先级队列中可能出现同个节点的多个拷贝，但是第2步保证了只对同个节点访问一次，其他拷贝会被自动舍弃）。至此，当前节点访问完毕。转2。

多连通域优先级搜索（pfs）的实现算法

多连通域的优先级搜索（pfs）只要遍历所有的节点，从每个尚未访问的节点出发进行一次单连通域优先级搜索即可，因此总的时间复杂度为O(n+e)。

最短路径的 Dijkstra 优先级更新器

由Dijkstra算法知，通过节点u去更新节点v的优先级的公式如下。

$$节点v的优先级 = min\left\{节点u的优先级 + 边(u,v)的权重, 节点v的优先级\right\}$$

边的权重说明

网络图构建（NetworkBuilding）中得到了两个用户之间的关系权重$relation(u,v)$，取其中最大者记做$MaxRelation$。

则在计算最短路径或者计算最小生成树中的边权重时采用如下公式。

$$weight(u,v) = \begin{cases} MaxRelation - relation(u,v), if(edge(u,v)exists) \\ \infty, else \end{cases}$$

通过这种方式计算出的最短路径，保证是通过那些关系较为密切的用户找到的一条最短路径，这与我们平常的逻辑较为吻合。

■ 根据用户指定计算最小生成树

最小生成树的Prim优先级更新器

由Prim算法知，通过节点u去更新节点v的优先级的公式如下。

$$\text{节点v的优先级} = \min\left\{\text{节点u的优先级} + \text{边}(u, v)\text{的权重}\right\}$$

其余算法与计算最短路径相同，不再赘述。

■ 根据用户指定（边阈值）计算图的连通分量

用户可以设定两个阈值，一个是用户关系的总阈值$thread$,另外一个是用户评分相似度的阈值$similarityThread$。

每个连通域通过编号$group$来区分。

算法

1. 从网络构建后的结果文件中删去所有边的权重小于$thread$或者小数部分小于$similarityThread$的边，构建出一个图。
2. 从某个未访问的节点 v 出发，设定其$group$就是自身的编号。其所有邻居节点的$group$和 v 相同，再从其邻居节点出发进行同样的访问。本质上是深度优先搜寻。搜索完毕后转 3。
3. 如果全图存在尚未访问的节点 v，则转 2。否则全图已经访问完毕。

因此总的时间复杂度为O(n+e)。

■ 节点的中心度

介数中心度的算法

1. 初始时所有结点的介数中心度=0
2. 对所有结点 s 进行下列操作：
   a) 若 s 为孤立点，则跳过；
   b) 否则，以 s 作为源点，调用 Dijkstra 算法求得 s 到所有结点（例如结点 t）的最短路径,每条最短路径 Pst 上除了 s 和 t 之外的所有结点的介数中心度加一。
3. 由于介数中心度在路径 Pst 和路径 Pts 中被重复计入，因此每个结点的介数中心度除以 2。

紧密中心度的算法

对所有结点 s 进行下列操作：

a) 若 s 为孤立点，则跳过；
b) 否则，以 s 作为源点，调用 Dijkstra 算法求得 s 到所有结点（例如结点 t）的最短路径。求 s 到其所在连通域的所有结点最短路径的平均值。该平均值越小，该结点越紧密。

算法效率分析

算法的主要瓶颈在于 Dijkstra 算法，由于使用了优先级队列，因此每次 Dijkstra 算法的时间复杂度都是 O(nlogn)。共调用 n 次，故总的时间复杂度为 $O(n^2 logn)$。

三、 选做项的说明

■ 网络图的构建 （以豆瓣影评数据为例）

用户关系的定义

假如两个用户A、B有看过相同的电影，则二者之间存在一条边。

该边的权重=共同看过的电影数目+评分近似程度

由于A看过的所有电影的平均分介于[0,10.0]，因此定义

A、B*的评分近似程度*

$$= \left(10.0 - \left|A\text{看过的电影平均分} - B\text{看过的电影平均分}\right|\right) \times 0.08 + 0.1$$

从而将他们的平均分之差（范围为[0,10]）映射到评分相似度（范围为[0.1,0.9]）

网络图的构建算法

1. 首先从Movie.csv中读入电影名称+评分，采用哈希表（QHash）存储电影，保证同样名称的电影只被加入一次。
2. 从User.csv中读入电影名称+用户名称，同样采用哈希表存储用户，每个用户看过的电影用集合（QSet）存储。同时将每个用户存入该电影的评论者中。
3. 对所有用户进行一次遍历，分别计算他们各自看过的电影的平均分。
4. 对所有的电影进行一次遍历，将每部电影的所有评论者两两关联。
5. 输出所有的关联边的两个端点和权重。

时间复杂度分析

设电影数目为N_1,一部电影最多的评论者为N_2,全图的边数为M

各个步骤的时间复杂度分别为

步骤	时间复杂度
1	$O(N_1)$
2	$O(N_1N_2)$
3	$O(N_1N_2)$
4	$O(N_1{N_2}^2)$
5	$O(M)$

从上表中可以发现，第4步是该算法主要消耗时间和空间的步骤。

■ 数据采集

我们用爬虫爬取了知乎的话题和关注用户，在网络构建中话题对应电影，关注话题的用户对应看过电影的用户，取消小数部分的边权。话题共有 1622 个，用户与话题的对应关系共有 32582 对。在可执行程序中可以选择使用哪个数据集。

■ 可视化分析

1. **界面简介**

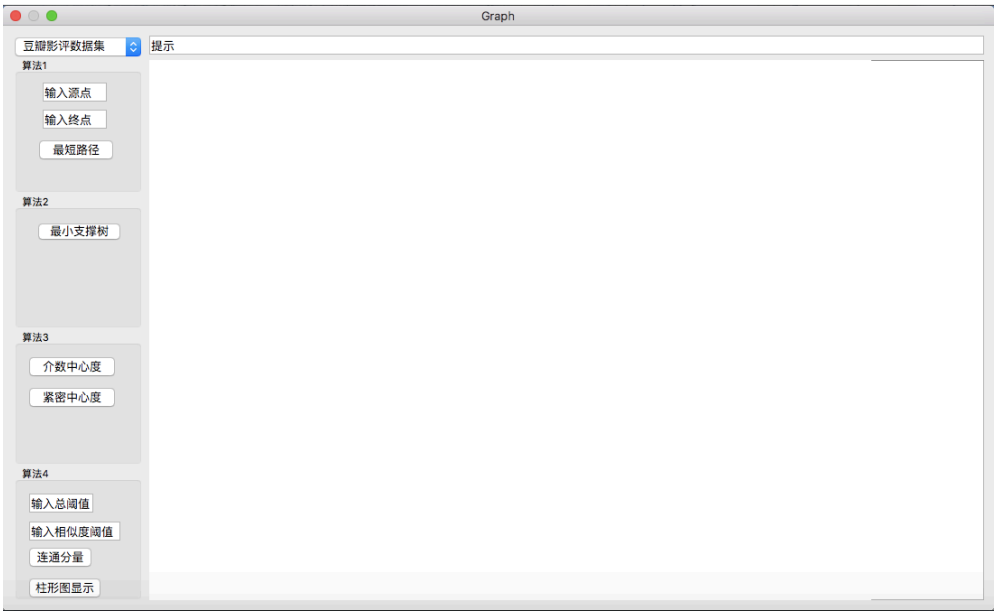

可于左上角选择数据集。

2. **最小生成树可视化结果**

注：只保留非孤立点的节点以加快d3的显示速度。

橙色点表示度数大于100的点，蓝色点表示度数大于10小于100的点

3. 最短路径可视化结果

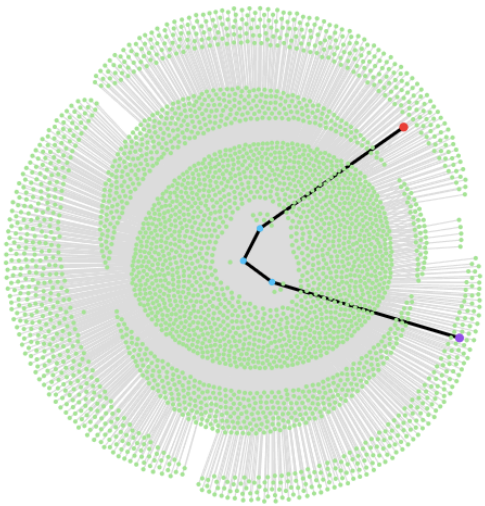

注：只保留最短路径以及和最短路径相邻的节点。

红点为起点，紫点为终点，蓝点为最短路径上的点，加粗的边即最短路径。

若输入的两点之间无路径，则会在提示框提示。

4. **中心度显示结果**

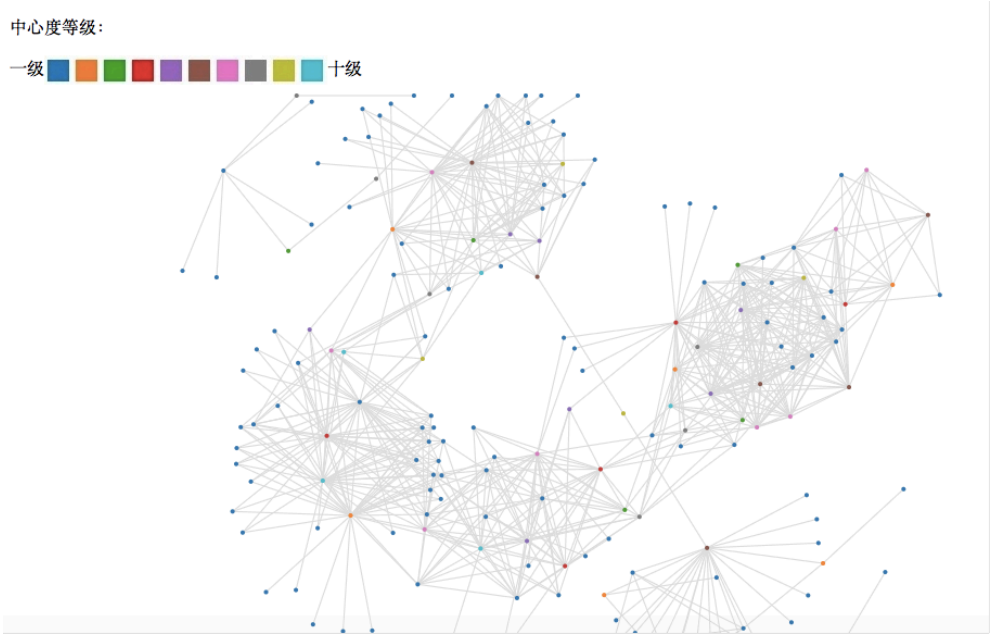

将中心度划分成是个等级，用不同颜色表示，使点的紧密度直观可见。

5. **给定阈值下的连通分量可视化结果**

第一张图为阈值较大时的结果，第二张图时阈值小一些的结果。不同颜色代表不同连通支。

6. 连通分量随阈值 t 变化情况

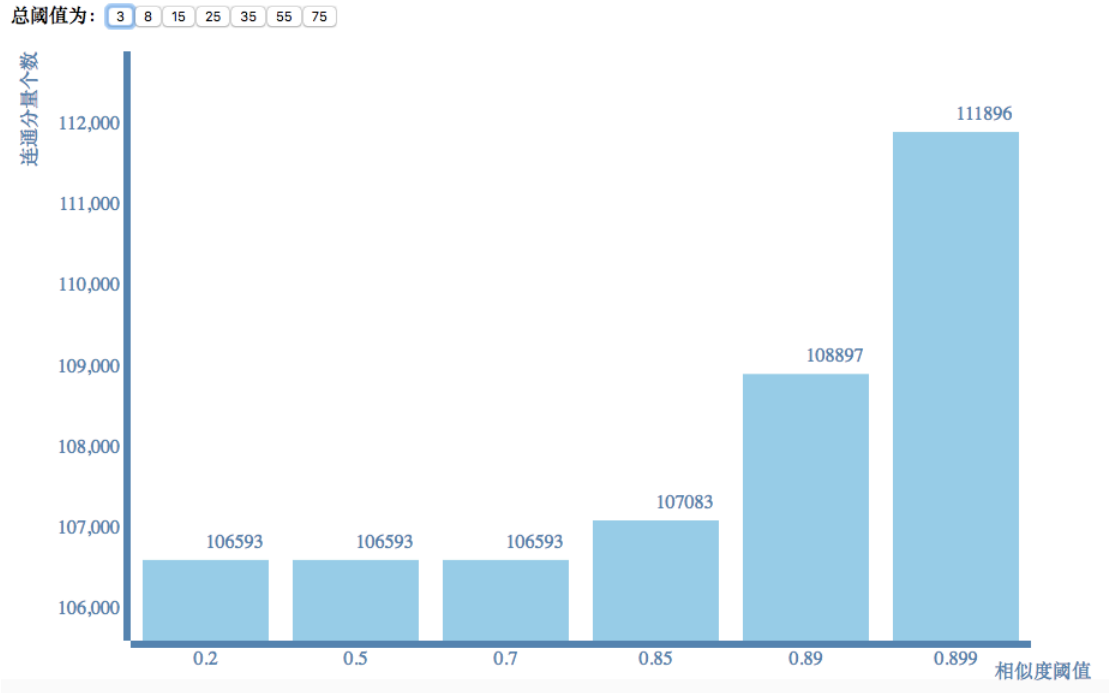

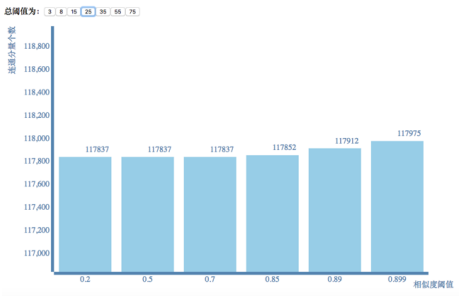

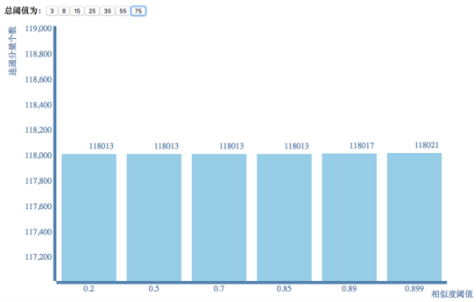

柱形图显示在总阈值给定（通过按钮进行

选择）的情况下相似度阈值与连通分量之间的关系。总阈值（整数部分）主要影响两个用户之间共同看过的电影数目，相似度阈值（小数部分）影响两个用户看过的电影的评分相似度。

由图可得：

1. 相同总阈值情况下，相似度阈值越大，连通分量个数越大；
2. 相同相似度阈值下，总阈值越大，连通分量个数越大；
3. 总阈值小的情况下，相似度阈值影响更大。
4. 总阈值在大于8之后，连通分量个数随总阈值变化程度较小。